



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ

Τεχνητή Νοημοσύνη

Msc "Ανεπτυγμένα Πληροφοριακά Συστήματα - Ανάπτυξη Λογισμικού και Τεχνητής
Νοημοσύνης

**Set-Based Learning with Emergent Label Dynamics
Theoretical Foundations and Implementation Using
Permutation-Invariant Models**

Φοιτητές:

Κωνσταντίνος Μητσιώνης

Αριθμός Μητρώου: mpsp2529, TNEΛ, mpsp2529@unipi.gr

Αναστασία Καπελλάκη

Αριθμός Μητρώου:

Επιβλέπων Καθηγητής:

Σωτηρόπουλος Διονύσιος

Περιεχόμενα

1	Εισαγωγή και κίνητρο εργασίας	2
2	Citeseer dataset	3
3	Deep Sets	5
3.1	Αποτελέσματα DeepSets στο Synthetic Dataset	8
3.2	Αποτελέσματα DeepSets στο Citeseer Dataset	9
4	SetTransformers	11
4.1	Αποτελέσματα SetTransformers στο συνθετικό dataset . . .	14
4.2	Αποτελέσματα SetTransformers στο Citeseer dataset	15
4.3	Σχολιασμός αποτελεσμάτων DeepSets και SetTransformers για το Citeseer dataset	16
4.3.1	Σημείωση για reproducibility	17
4.3.2	Ανάλυση ευαισθησίας: Το αντίκτυπο του weight initialization	17
4.4	Ερευνητικά ερωτήματα	18
4.4.1	Expressivity analysis	18
4.4.2	Invariance vs. Equivariance	20

Κεφάλαιο 1

Εισαγωγή και κίνητρο εργασίας

Η παρούσα εργασία αναλύει θεωρητικά και υλοποιεί νευρωνικά δίκτυα που είναι αναλλοίωτα ως προς τη σειρά των στοιχείων εισόδου (permutation invariant), δηλαδή δίκτυα για τα οποία οποιαδήποτε αναδιάταξη των στοιχείων εισόδου, δεν επηρεάζει την έξοδο που παράγουν. Συγκεκριμένα, χρησιμοποιούνται δύο dataset με διαφορετικά χαρακτηριστικά: ένα συνθετικό dataset με σταθερό αριθμό γειτόνων ανά σημείο και το Citeseer dataset, ένα πραγματικό γράφημα αναφορών επιστημονικών εργασιών με μεταβλητό αριθμό γειτόνων. Και στις δύο περιπτώσεις, το πρόβλημα διατυπώνεται ως εξής: δοθέντος ενός κόμβου και του συνόλου των γειτόνων του, να προβλεφθεί η ετικέτα του κόμβου είτε μέσω δυαδικής κατηγοριοποίησης για το συνθετικό dataset είτε μέσω κατηγοριοποίησης πολλών κλάσεων (6 κλάσεις) για το Citeseer dataset. Το σημαντικό χαρακτηριστικό αυτών των συνόλων δεδομένων είναι ότι το σύνολο των γειτόνων ενός κόμβου δεν έχει φυσική σειρά, δηλαδή δεν υπάρχει κάποιο νόημα στη σειρά με την οποία παρατίθενται οι γείτονες ενός κόμβου. Τα μοντέλα που εξετάζονται, διαθέτουν αρχιτεκτονική που εγγυάται την αναλλοίωτη συμπεριφορά τους ανεξάρτητα της σειράς που παρατίθενται τα διανύσματα εισόδου, μέσω της χρήσης αθροιστικής συνάρτησης συγκέντρωσης (sum-pooling) που είναι από τη φύση της αντιμεταθετική ή μέσω μηχανισμών προσοχής (attention mechanisms).

Κεφάλαιο 2

Citeseer dataset

Το Citeseer dataset είναι ένα πραγματικό γράφημα για επιστημονικές δημοσιεύσεις όπου κάθε κόμβος αντιστοιχεί σε ένα επιστημονικό άρθρο (paper) και οι ακμές του σε αναφορές (citations) όπου υπάρχουν μεταξύ των δημοσιεύσεων. Το γράφημα προορίζεται για την κατηγοριοποίηση των δημοσιεύσεων σε ερευνητικές περιοχές και αποτελείται από 3327 κόμβους όπου ο καθένας περιέχει 3703 διαστάσεις τύπου bag-of-words, 9104 ακμές, ενώ οι συνολικές κατηγορίες στις οποίες μπορούν να ενταχθούν οι δημοσιεύσεις είναι 6. Για το γράφημα αυτό, το Planetoid split χωρίζει το data σε 120 training κόμβους (20 από κάθε κλάση), σε 500 validation κόμβους και σε 1000 που προορίζονται για testing. Για την εκπαίδευση στο εν λόγω σύνολο δεδομένων ακολουθείται transductive learning, που σημαίνει ότι ολόκληρη η δομή του γράφου είναι "ορατή" κατά την εκπαίδευση αλλά οι ετικέτες του validation και testing dataset είναι εντελώς κρυμμένες.

Το input για την κατηγοριοποίηση κάθε κόμβου είναι της μορφής:

$$\{\text{features}(v_i), \text{features}(u_1), \dots, \text{features}(u_m)\}$$

όπου συμπεριλαμβάνεται το διάνυσμα 3703 διαστάσεων του προς κατηγοριοποίηση κόμβου και τα διανύσματα των m γειτόνων του. Το edge_index του citation γράφου, προσδιορίζει ποίοι κόμβοι είναι γείτονες και όχι κάποια υπολογιζόμενη απόσταση όπως στη περίπτωση του συνθετικού dataset όπου χρησιμοποιήθηκε ο kNN αλγόριθμος.

Η δομική διαφορά αυτού του dataset με το συνθετικό, είναι πως στη συγκεκριμένη περίπτωση, ο αριθμός των γειτόνων κάθε κόμβου δεν είναι εξ αρχής προκαθορισμένος. Κάθε δημοσίευση έχει διαφορετικό πλήθος γειτόνων μιας και ένα paper μπορεί να έχει αναφερθεί από πολλά, λίγα ή

κανένα άλλο paper. Για τη μοντελοποίηση αυτής της ιδιαιτερότητας, ορίστηκε μέγιστος αριθμός γειτόνων $\text{MAX_NEIGHBORS}=20$. Η επιλογή αυτή δικαιολογείται εμπειρικά από την κατανομή βαθμού (degree distribution) του γράφου: ο μέσος βαθμός είναι 2.74, η διάμεσος 2, υπάρχουν 48 απομονωμένοι κόμβοι (βαθμός 0), και μόνο 13 από τους 3327 κόμβους (0.4%) ξεπερνούν τους 20 γείτονες. Σε περιπτώσεις όπου ο αριθμός των γειτόνων είναι μικρότερος του 20, εφαρμόζεται zero-padding στις εναπομείναντες θέσεις. Παράλληλα, δημιουργήθηκε boolean neighbor_mask μέσω της οποίας διακρίνονται οι πραγματικοί γείτονες από τις θέσεις zero-padding. Κρίσιμο σημείο είναι ότι η εφαρμογή της μάσκας πρέπει να γίνεται μετά την εφαρμογή της συνάρτησης ϕ και όχι στην ακατέργαστη είσοδο. Αυτό συμβαίνει διότι $\phi(\text{zero_vector}) \neq 0$ λόγω των bias terms των γραμμικών στρωμάτων — οι κενές θέσεις zero-padding θα συνεισέφεραν μη μηδενικές τιμές στο άθροισμα, αλλοιώνοντας την αναπαράσταση κάθε κόμβου που έχει λιγότερους από 20 γείτονες. Η εφαρμογή της μάσκας μετά το ϕ διασφαλίζει ότι μόνο οι πραγματικοί γείτονες συμβάλλουν στο sum-pooling.

Κεφάλαιο 3

Deep Sets

Τα Deep Sets [3] προτείνουν μια αρχιτεκτονική νευρωνικών δικτύων για την επεξεργασία συνόλων δεδομένων (sets), όπου η έξοδος του μοντέλου πρέπει να είναι ανεξάρτητη από τη σειρά με την οποία παρουσιάζονται τα στοιχεία εισόδου. Ένα τυπικό MLP δεν διαθέτει αυτή την ιδιότητα: εάν τα στοιχεία ενός συνόλου τροφοδοτηθούν ως διάνυσμα σταθερής θέσης, η ανακατάταξή τους παράγει διαφορετική έξοδο, παρόλο που το υποκείμενο σύνολο παραμένει το ίδιο. Σύμφωνα με την επιστημονική ανάλυση, μια συνάρτηση είναι permutation invariant, δηλαδή ισχύει:

$$f(\{x_1, \dots, x_M\}) = f(\{x_{\pi(1)}, \dots, x_{\pi(M)}\}) \quad \text{for any permutation } \pi$$

αν και μόνο αν μπορεί να γραφτεί ως συνάρτηση του ρ και φ :

$$f(S) = \rho\left(\sum_{x \in S} \varphi(x)\right)$$

Οι δύο κατευθύνσεις της απόδειξης, χρίζουν ρητής αιτιολόγησης και ανάλυσης. Η επάρκεια, ότι δηλαδή η μορφή $f(S)$ αποτελεί μια permutation invariant συνάρτηση αποδεικνύεται τετριμμένα: η εφαρμογή της ίδιας συνάρτησης σε ένα σύνολο δεδομένων και το άθροισμα των αποτελεσμάτων παράγει πάντα το ίδιο αποτέλεσμα, ανεξαρτήτως της σειράς λόγω της αντιμεταθετικής ιδιότητας της πρόσθεσης. Η αναγκαιότητα όμως, ότι δηλαδή κάθε permutation invariant συνάρτηση γράφεται σε αυτή τη μορφή, είναι ένα ενδιαφέρον και χρήσιμο συμπέρασμα. Αν για παράδειγμα οριστεί $\varphi(x) = 4^{-c(x)}$ όπου $c(x)$ το μοναδικό αναγνωριστικό κάθε στοιχείου, το άθροισμα $\sum_{x \in S} \varphi(x)$ λειτουργεί ως μοναδικό αποτύπωμα του συνόλου S , μιας και έχοντας την τιμή του αθροίσματος, είναι εφικτή η ανακατασκευή

του S . Η λογική είναι η εξής: κάθε στοιχείο καταλαμβάνει μια ιδιωτική ψηφιακή θέση σε έναν αριθμό βάσης 4, οπότε διαφορετικά σύνολα παράγουν πάντα διαφορετικό άθροισμα.

$$E(\{A, C\}) = 4^{-1} + 4^{-3} = 0.265625$$

$$E(\{B, D\}) = 4^{-2} + 4^{-4} = 0.066406$$

Τα δύο αθροίσματα είναι διαφορετικά, και αυτό ισχύει για κάθε ζεύγος διαφορετικών συνόλων. Δοθέντος λοιπόν μόνο του $z = E(S)$, η κατασκευή του S είναι εφικτή διαβάζοντας τα ψηφία βάσης 4. Επομένως, οποιαδήποτε συνάρτηση $f(S)$ μπορεί να γραφτεί ως $\rho(\sum_{x \in S} \varphi(x))$, ορίζοντας $\rho(z) := f(S)$ για το μοναδικό S που αντιστοιχεί στο z , αποδεικνύοντας έτσι την αναγκαιότητα.

Σημειώνεται ότι αυτή η κατασκευή ισχύει για καταριθμήσιμα (countable) σύνολα, όπου κάθε στοιχείο μπορεί να λάβει ακέραιο αναγνωριστικό $c(x)$. Για συνεχή διανύσματα — όπως τα 16-διάστατα διανύσματα του συνθετικού dataset ή τα 3703-διάστατα του CiteSeer — το paper επεκτείνει την απόδειξη μέσω πιο προχωρημένων μαθηματικών εργαλείων, χωρίς να αλλάζει το βασικό συμπέρασμα.

Το Θεώρημα 2 εγγυάται την ύπαρξη κατάλληλων συναρτήσεων φ και ρ τις οποίες όμως δεν προσδιορίζει. Σύμφωνα όμως με το θεώρημα Καθολικής προσέγγισης (UAT), ένα MLP με τουλάχιστον ένα κρυφό στρώμα και μη γραμμική συνάρτηση ενεργοποίησης, μπορεί να προσεγγίσει οποιαδήποτε συνεχή συνάρτηση με την επιθυμητή ακρίβεια. Συνοψίζοντας, το Θεώρημα 2 [3] υποστηρίζει ότι οι κατάλληλες φ και ρ υπάρχουν ώστε να προσεγγιστούν οι permutation invariant συναρτήσεις, ενώ το UAT διαβεβαιώνει πως τα νευρωνικά δίκτυα μπορούν να μάθουν τις φ και ρ συναρτήσεις.

Έτσι, η συνάρτηση φ μπορεί να οριστεί ως ένα MLP (Linear $\rightarrow$ ReLU $\rightarrow$ Linear) το οποίο εφαρμόζεται με τα ίδια βάρη, ανεξάρτητα σε κάθε στοιχείο του set, ικανοποιώντας και τις συνθήκες του UAT. Το sum-pooling βήμα που ακολουθεί στη συνέχεια κάνει συμπίεση στις διαστάσεις του set. Στη συνέχεια το ρ αποτελείται από ένα δεύτερο MLP ίδιας αρχιτεκτονικής, μέσω του οποίου παράγονται τα τελικά logits. Αξίζει να σημειωθεί πως δεν χρησιμοποιήθηκε στο τελευταίο layer κάποιο ReLU function, γιατί σε αυτή την περίπτωση το μοντέλο δεν θα μπορούσε να εκφράσει αρνητικά logits

για κάποιες κλάσεις και αντιθέτως να εκφράσει την "σιγουριά" του για κάποια άλλη.

Το sum-pooling συσσωρεύει την επίδραση της γειτονιάς σε κάθε διάσταση του κρυφού διανύσματος, όπου κάθε διάσταση αντιστοιχεί σε ένα χαρακτηριστικό που έμαθε η ϕ κατά τη διάρκεια της εκπαίδευσης. Επομένως το ρ δεν δέχεται δεδομένα για κάθε κόμβο ξεχωριστά, αλλά μια συμπυκνωμένη αναπαράσταση πληροφορίας για κάθε set του batch, κάτι που επιβεβαιώνει την αρχική προδιαγραφή, ότι η ετικέτα ενός κόμβου δεν εξαρτάται από τη σειρά παρουσίασης των γειτόνων, αλλά από τη συνολική σύνθεση της γειτονιάς ως σύνολο.

Η επιλογή του αθροίσματος (sum) έναντι του μέσου όρου (mean) ως συνάρτηση συγκέντρωσης (pooling sum) δεν είναι τυχαία. Για σύνολα σταθερού μεγέθους, οι δύο επιλογές είναι ισοδύναμες, μιας και ο μέσος όρος είναι απλώς το άθροισμα διαιρεμένο με σταθερά, οπότε το ρ μπορεί εσωτερικά να αντιστρέψει αυτή τη διαίρεση. Για σύνολα μεταβλητού μεγέθους όμως — όπως στο CiteSeer όπου ο βαθμός κάθε κόμβου ποικίλλει — το mean-pooling μπορεί να συρρικνώσει δύο διαφορετικά σύνολα στην ίδια αναπαράσταση. Για παράδειγμα, τα σύνολα $\{2, 4\}$ και $\{1, 3, 5\}$ έχουν και τα δύο μέσο όρο 3, αλλά αθροίσματα 6 και 9 αντίστοιχα. Το sum-pooling διατηρεί αυτή τη διάκριση, ενώ το mean-pooling την χάνει — καθιστώντας το sum θεωρητικά πιο εκφραστικό για σύνολα μεταβλητού μεγέθους.

Η επέκταση που εισάγεται στο πλαίσιο αυτής της εργασίας είναι η εφαρμογή μάσκας στο sum-pooling για τον χειρισμό του μεταβλητού αριθμού των γειτόνων και εκφράζεται ως:

$$\text{pooled} = \sum_j \phi(x_j) \cdot \text{mask}_j$$

Ο πολλαπλασιασμός με την μάσκα γίνεται μετά το ϕ και όχι πριν, μιας και σε αντίθετη περίπτωση $\phi(\mathbf{0}) \neq \mathbf{0}$ λόγω των bias terms που διαθέτουν οι αρχιτεκτονικές.

Στον παρακάτω πίνακα παρουσιάζονται συγκριτικά τα δεδομένα για τα δύο διαφορετικά dataset:

	Synthetic	CiteSeer
input_dim	16	3703
set_size	11 (fixed)	21 (με padding)
hidden_dim	32	32
output	1 logit και sigmoid	6 logits και argmax
loss	BCEWithLogitsLoss	CrossEntropyLoss
mask needed	No	Yes

Πίνακας 3.1: Αρχιτεκτονικά χαρακτηριστικά και παράμετροι εκπαίδευσης για τα δύο dataset.

3.1 Αποτελέσματα DeepSets στο Synthetic Dataset

Για τη διεξαγωγή του πειράματος με το συνθετικό dataset χρησιμοποιήθηκαν 50000 δείγματα, τα οποία προέρχονται από τις κανονικές κατανομές $\mathcal{N}(0, 1)$ and $\mathcal{N}(1, 1)$ σε χώρο 16 διαστάσεων. Για την εκπαίδευση του μοντέλου χρησιμοποιήθηκε το άνω όριο των 50 epochs, βελτιστοποιητής Adam με learning rate 10^{-3} , και μηχανισμός early stopping με patience=5 και min_delta=0.001, ο οποίος τερματίζει τη διαδικασία της εκπαίδευσης σε περίπτωση που το validation loss δεν βελτιώνεται για 5 συνεχόμενα epochs. Κατά τον τερματισμό της εκπαίδευσης διατηρείται το state του μοντέλου με το καλύτερο validation loss και αξιολογείται πάνω στο test set, το οποίο δεν συμμετέχει καθόλου στην εκπαίδευση.

Στα 50000 δείγματα, το 5.37% των δειγμάτων άλλαξαν ετικέτα λόγω των γειτόνων τους, αποτελώντας τα "ambiguous σημεία". Ένα μοντέλο που αγνοεί εντελώς τη γειτονιά και βασίζεται μόνο στα χαρακτηριστικά του ίδιου του κόμβου αναμένεται να φτάνει κατ' ανώτατο όριο στο 94.63% accuracy, καθώς τα ambiguous σημεία έχουν ετικέτα που αντιφάσκει με τη δική τους κατανομή. Το μοντέλο επιτυγχάνει test accuracy 96.16%, υπερβαίνοντας αυτό το όριο κατά 1.53 ποσοστιαίες μονάδες, γεγονός που αποτελεί άμεση απόδειξη ότι το μοντέλο αξιοποιεί πληροφορία από τη γειτονιά και όχι μόνο από το ίδιο το σημείο.

Το μοντέλο τερματίζει την εκπαίδευσή του στο 12ο epoch και τα αποτελέσματα που δίνει είναι τα εξής:

$$\text{Best epoch's val loss} = 0.076999$$

$$\text{Test loss} = 0.080648$$

$$\text{Test accuracy} = 0.9616$$

3.2 Αποτελέσματα DeepSets στο Citeseer Dataset

Για τη διεξαγωγή του πειράματος με το CiteSeer dataset αξιοποιήθηκαν όλα τα 3.327 δείγματα, εκ των οποίων μόνο τα 120 χρησιμοποιούνται με γνωστή ετικέτα κατά την εκπαίδευση (20 ανά κλάση), τα 500 στο validation και τα 1.000 κατά το testing. Τα υπόλοιπα δείγματα συμμετέχουν στη διαμόρφωση της δομής της γειτονιάς, καθώς τα χαρακτηριστικά και οι ακμές τους είναι ορατά κατά την εκπαίδευση αλλά οι ετικέτες τους παραμένουν κρυμμένες, σύμφωνα με το transductive learning πλαίσιο.

Για την περίπτωση αυτή υλοποιήθηκε νέα κλάση με όνομα DeepSetsModelCiteseer, αρχιτεκτονικά ίδια με αυτή του συνθετικού dataset, με δύο διαφορές: η έξοδος του ρ παράγει 6 logits (αντί για 1) για την πολυκλασική κατηγοριοποίηση, και το sum-pooling εφαρμόζει πολλαπλασιασμό με την neighbor_mask μετά το ϕ , για τον χειρισμό του μεταβλητού αριθμού γειτόνων. Όμοια με το μοντέλο του συνθετικού dataset, χρησιμοποιήθηκε βελτιστοποιητής Adam με learning rate 10^{-3} , άνω όριο 50 epochs, και early stopping με patience=5 και min_delta=0.001. Κατά τον τερματισμό διατηρείται το checkpoint με το καλύτερο validation loss, το οποίο αξιολογείται μία φορά στο test set.

Το μοντέλο τερματίζει την εκπαίδευσή του στο 28ο epoch, λόγω early stopping. Αξιοσημείωτη παρατήρηση είναι το training accuracy που ισούται με την μονάδα από το 19ο epoch και μετά, την ώρα που το validation accuracy σταθεροποιείται γύρω στο 60% οδηγώντας στο συμπέρασμα ότι το μοντέλο απομνημονεύει τα 120 δείγματα, αλλά δεν μπορεί να γενικεύσει σε άγνωστες περιπτώσεις που εμφανίζονται στο validation set. Αυτό απορρέει και από το transductive learning πλαίσιο της εκπαίδευσης μιας και η πλειοψηφία των κόμβων συμβάλλει μόνο στη διαμόρφωση της δομής του δικτύου και όχι στον υπολογισμό του loss, μιας και δεν διαθέτουν ετικέτα.

Το αποτέλεσμα αυτό τοποθετείται ανάμεσα σε δύο σημεία αναφοράς από τη βιβλιογραφία: ένα απλό MLP που αγνοεί εντελώς τη δομή του γράφου επιτυγχάνει 52.9% accuracy στο CiteSeer, ενώ πλήρεις αρχιτεκτονικές GNN όπως το GCN (67.5%) και το GAT (70.6%) εκμεταλλεύονται επαναληπτικά τη δομή του γράφου για υψηλότερες επιδόσεις [1]. Το Deep Sets (60.0%) υπερβαίνει το MLP baseline κατά 7.1 μονάδες, επιβεβαιώνοντας ότι η αξιοποίηση της "γειτονιάς" μέσω sum-pooling προσφέρει πραγματικό

πλεονέκτημα στην βελτίωση της απόδοσης του μοντέλου.

Τα αποτελέσματα που λαμβάνονται είναι τα εξής:

Best epoch's val loss = 1.180531

Test loss = 1.182613

Test accuracy = 0.6

Κεφάλαιο 4

SetTransformers

Στην περίπτωση των DeepSets η συνάρτηση $\varphi : \mathbb{R}^{16} \rightarrow \mathbb{R}^{32}$ εφαρμόζεται σε κάθε ένα από τα 11 στοιχεία του set ξεχωριστά και ανεξάρτητα, δεχόμενη ως είσοδο tensor μεγέθους (64,11,16) και παράγοντας έξοδο μεγέθους (64,11,32). Η έξοδος αυτή περιέχει 11 αναπαραστάσεις οι οποίες διαμορφώθηκαν χωρίς η μια να επιδρά στον υπολογισμό της άλλης καθώς κάθε στοιχείο επεξεργάστηκε σε πλήρη απομόνωση. Το μέρος όπου οι 11 αυτές αναπαραστάσεις συναντώνται είναι κατά το sum-pooling, κατά το οποίο οι ήδη καθορισμένες αναπαραστάσεις προστίθενται με ίσα βάρη, χωρίς καμία έννοια συσχέτισης μεταξύ των στοιχείων.

Στην περίπτωση των SetTransformers, μετά την προβολή της εισόδου σε χώρο $d = 32$ διαστάσεων μέσω γραμμικού στρώματος (64,11,16) $\rightarrow$ (64,11,32), το SAB block εφαρμόζεται στο σύνολο των στοιχείων ταυτόχρονα. Η αναπαράσταση κάθε στοιχείου στο set εκφράζεται ως σταθμισμένος συνδυασμός των αναπαραστάσεων όλων των στοιχείων του set, με τα βάρη να υπολογίζονται μέσα από τη συσχέτιση του στοιχείου με όλα τα υπόλοιπα, σύμφωνα με τον attention μηχανισμό. Έτσι όταν φτάνουμε στο pooling του PMA block, ένα εκπαιδευσιμο διάνυσμα (seed) επιλέγει ποια από τα ήδη εμπλουτισμένα στοιχεία είναι πιο "σχετικά" για την πρόβλεψη παράγοντας μια σταθμισμένη αναπαράσταση αντί μιας άθροισης με ίσα βάρη στην οποία δεν αποτυπώνεται η πληροφορία της "σχετικότητας" μεταξύ των στοιχείων.

Όσο αφορά την αρχιτεκτονική των SetTransformers, αυτή αποτελείται από πολλά επιμέρους στάδια.

Αρχικά, ένα από τα θεμέλια της αρχιτεκτονικής αυτής είναι ο μηχανι-

σμός προσοχής. Στο στάδιο αυτό υπάρχουν τρεις πίνακες: Q (Query) που δείχνει τι ψάχνει κάθε στοιχείο, K (Key) που φανερώνει τι περιέχει κάθε στοιχείο, και V (Value) στον οποίο αποτυπώνεται η πληροφορία που προσφέρεται αν ένα στοιχείο επιλεγεί. Ο τύπος για τον μηχανισμό προσοχής είναι:

$$\text{Att}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

Το γινόμενο $QK^\top$ υπολογίζει την σχετικότητα μεταξύ κάθε ζεύγους Query-Key, ενώ η διαίρεση με το $\sqrt{d_k}$ είναι απαραίτητη μιας και αποτρέπει ενδεχόμενες μεγάλες τιμές στο softmax, οι οποίες αν προκύψουν καθιστούν την εκπαίδευση ιδιαίτερα ασταθή διαδικασία. Το softmax μετατρέπει αυτές τις τιμές που προκύπτουν σε βάρη α_{ij} που αθροίζουν στη μονάδα, ενώ η έξοδος για κάθε στοιχείο i είναι ο σταθμισμένος συνδυασμός όλων των διανυσμάτων Value $\sum_j \alpha_{ij} V_j$.

Στο πλαίσιο της παρούσας εργασίας για το συνθετικό dataset, ισχύει ότι $Q, K, V \in \mathbb{R}^{11 \times 8}$ ανά κεφαλή και ανά δείγμα ($d_k = d/h = 32/4 = 8$), ο πίνακας βαθμολογιών $QK^\top \in \mathbb{R}^{11 \times 11}$ με κάθε στοιχείο να βαθμολογεί κάθε άλλο, και η έξοδος $\in \mathbb{R}^{11 \times 8}$. Στην υλοποίηση, ο πλήρης πίνακας `attn_scores` έχει μέγεθος (64, 4, 11, 11), όπου οι διαστάσεις αναφέρονται σε batch, κεφαλές, στοιχεία, στοιχεία. Μετά τη συνένωση των κεφαλών και την προβολή μέσω W_O , η τελική έξοδος επανέρχεται στο (64, 11, 32).

Αντίστοιχα, για το CiteSeer dataset, $Q, K, V \in \mathbb{R}^{21 \times 8}$ ανά κεφαλή και ανά δείγμα ($d_k = 8$), ο πίνακας βαθμολογιών $QK^\top \in \mathbb{R}^{21 \times 21}$ και η έξοδος $\in \mathbb{R}^{21 \times 8}$. Στην υλοποίηση, ο πλήρης `attn_scores` έχει μέγεθος (64, 4, 21, 21). Για τις θέσεις zero-padding, οι αντίστοιχες βαθμολογίες τίθενται ίσες με -10^9 πριν το softmax, ώστε τα βάρη α_{ij} των θέσεων όπου χρησιμοποιήθηκε zero padding να τείνουν στο μηδέν και να μη συμβάλλουν στον τελικό σταθμισμένο συνδυασμό. Μετά τη συνένωση των κεφαλών και την προβολή μέσω W_O , η τελική έξοδος επανέρχεται στο (64, 21, 32).

Η MultiHeadAttention δομή, εκτελεί τον μηχανισμό της προσοχής παράλληλα σε $h=4$ ανεξάρτητες κεφαλές, με την κάθε κεφαλή να δουλεύει σε ένα διαφορετικό 8-διάστατο υποχώρο. Αυτό συμβαίνει με στόχο κάθε κεφαλή, να μάθει διαφορετικά είδη συσχετίσεων μεταξύ των δεδομένων. Τα αποτελέσματα από όλες τις κεφαλές συνενώνονται και προκύπτει το

τελικό αποτέλεσμα. Ο μαθηματικός τύπος που περιγράφει τη διαδικασία είναι:

$$\text{MultiHead}(Q, K, V) = \text{concat}(O^{(1)}, \dots, O^{(h)})W_O$$

όπου κάθε $O^{(l)} = \text{Att}(QW_Q^{(l)}, KW_K^{(l)}, VW_V^{(l)})$ για κάθε l κεφαλή.

Όπως αναφέρεται και παραπάνω κάθε κεφαλή παράγει ένα `attn_score` διάστασης $(64, 4, 11, 11)$ για την περίπτωση του συνθετικού dataset και $(64, 4, 21, 21)$ για την περίπτωση του Citeseer dataset. Στη συνέχεια τα διανύσματα αυτά συνενώνονται και προβάλλονται μέσω του W_O με αποτέλεσμα να προκύπτουν τα αποτελέσματα διαστάσεων $(64, 11, 32)$ και $(64, 21, 32)$ αντίστοιχα.

Το MAB είναι μια κλάση η οποία περικλείει τη διαδικασία του MultiHeadAttention, προσφέροντας στη διαδικασία δύο μηχανισμούς σταθεροποίησης, τις συνδέσεις ανατροφοδότησης και το LayerNorm. Το MAB δέχεται δύο εισόδους: το X παρέχει τα queries, ενώ το Y παρέχει τα keys και values. Αυτή η ασυμμετρία είναι που επιτρέπει στο ίδιο block να χρησιμοποιηθεί τόσο στο SAB όσο και στο PMA με διαφορετικές εισόδους. Οι συνδέσεις ανατροφοδότησης διαβεβαιώνουν ότι τα αρχικά χαρακτηριστικά των στοιχείων θα ληφθούν υπόψιν ακόμα και αν ο μηχανισμός προσοχής δεν παράξει χρήσιμη πληροφορία για τις συσχετίσεις που υπάρχουν, καθιστώντας πιο σταθερή τη διαδικασία της εκπαίδευσης. Το πέρασμα του αποτελέσματος από ένα μικρό feed forward network μετά την εφαρμογή του μηχανισμού προσοχής στοχεύει στην είσοδο μη γραμμικότητας στην τελική έξοδο. Οι εξισώσεις που περιγράφουν τη λειτουργία του MAB είναι:

$$H = \text{LayerNorm}(X + \text{MultiHead}(X, Y, Y))$$

$$\text{MAB}(X, Y) = \text{LayerNorm}(H + \text{rFF}(H))$$

Το SAB αξιοποιεί την ήδη καθορισμένη MAB κλάση, με τη διαφορά πως και τα δύο ορίσματα είναι ίσα με το X . Αυτό σημαίνει πως παρέχονται και τα keys και τα values του X , με αποτέλεσμα κάθε στοιχείο να "απευθύνεται" ταυτόχρονα στα υπόλοιπα στοιχεία του set για τη δημιουργία αναπαραστάσεων. Η εξίσωση που περιγράφει τη διαδικασία είναι:

$$\text{SAB}(X) = \text{MAB}(X, X)$$

Το αποτέλεσμα είναι η δημιουργία εμπλουτισμένων αναπαραστάσεων του X όπου κάθε στοιχείο λαμβάνει υπόψιν την ύπαρξη και των υπόλοιπων στοιχείων στο set. Το SAB διατηρεί τις διαστάσεις (64, 11, 32) και (64, 21, 32) για το συνθετικό και το Citeseer dataset αντίστοιχα, επιτρέποντας με αυτόν τον τρόπο την τοποθέτηση παραπάνω εκ του ενός SAB στη σειρά, με στόχο την πιο "βαθεία" δημιουργία νέων αναπαραστάσεων.

Κατά την εκτέλεση της κλάσης PMA, το set μετατρέπεται σε single vector, όχι με απλή πρόσθεση όπως στην περίπτωση του sum-pooling στα Deep Sets, αλλά μέσω ενός επιλεκτικού μηχανισμού. Ο μαθηματικός τύπος που περιγράφει τη διαδικασία είναι:

$$\text{PMA}_k(Z) = \text{MAB}(S, \text{rFF}(Z))$$

Το $S \in \mathbb{R}^{k \times d}$ είναι εκπαιδύσιμη παράμετρος (seed) που παρέχει τα queries, ενώ το $\text{rFF}(Z)$ παρέχει τα keys και values, όπου $Z \in \mathbb{R}^{64 \times 11 \times 32}$ (συνθετικό) ή $\mathbb{R}^{64 \times 21 \times 32}$ (CiteSeer) είναι η έξοδος της στοίβας SAB blocks. Στην παρούσα εργασία χρησιμοποιείται $k = 1$, δηλαδή ένα μόνο seed vector, με αποτέλεσμα ο πίνακας βαθμολογιών εντός του PMA να έχει μέγεθος (64, 4, 1, 11) για το συνθετικό και (64, 4, 1, 21) για το CiteSeer, δηλαδή 1 query για M keys. Στο σημείο αυτό γίνεται συμπίεση της διάστασης του set για πρώτη φορά, παράγοντας έξοδο (64, 1, 32) η οποία μετά το squeeze γίνεται (64, 32) και τροφοδοτεί το ρ . Η διαδικασία αυτή έρχεται σε αντίθεση με τα Deep Sets όπου το sum-pooling προσθέτει όλα τα στοιχεία με ίσα βάρη. Στο PMA τα βάρη α_{ij} υπολογίζονται δυναμικά μέσω του seed, με τα στοιχεία που είναι πιο σχετικά με την πρόβλεψη να λαμβάνουν αυτόματα υψηλότερο βάρος.

4.1 Αποτελέσματα SetTransformers στο συνθετικό dataset

Στην περίπτωση του συνθετικού dataset, η εκπαίδευση τερματίζει μετά από 13 epochs, λόγω της εφαρμογής ίδιου EarlyStopping με την περίπτωση του DeepSets. Συγκριτικά με την αντίστοιχη περίπτωση στο DeepSets η διαφορά είναι της τάξης του 0.36%, στοιχείο που υποδηλώνει σχεδόν ίδια απόδοση των δύο μοντέλων σε αυτή τη περίπτωση. Αναλυτικά, τα αποτελέσματα που λαμβάνονται στην περίπτωση των SetTransformers είναι:

Best epoch's val loss = 0.078300

Test loss = 0.084660

Test accuracy = 0.958

Στην δοκιμή που πραγματοποιήθηκε για setTransformers με ένα SAB block τα αποτελέσματα είναι τα εξής:

Best epoch's val loss = 0.077564

Test loss = 0.083386

Test accuracy = 0.957200

4.2 Αποτελέσματα SetTransformers στο Citeseer dataset

Στην περίπτωση του Citeseer dataset, η εκπαίδευση τερματίζει μετά από 33 epochs, με τα αποτελέσματα να εμφανίζουν μεγαλύτερο ενδιαφέρον ως προς τον σχολιασμό τους. Παρά το μηχανισμό προσοχής που υλοποιείται και θεωρητικά έπρεπε να ερμηνεύει καλύτερα τις συσχετίσεις κόμβων με τους γείτονές του, παρατηρείται πτώση στο accuracy κατά περίπου 10 μονάδες συγκριτικά με την αντίστοιχη υλοποίηση στο DeepSets. Η μείωση των SAB blocks από 2 σε 1 βελτιώνει μερικώς την απόδοση. Παρόλα αυτά εδώ προτιμάται η χρήση 2 SAB blocks για την όσο δυνατόν μεγαλύτερη προσομοίωση γίνεται του αντίστοιχου paper [2]. Αναλυτικά, τα αποτελέσματα που λαμβάνονται στην περίπτωση των SetTransformers είναι:

Best epoch's val loss = 1.122532

Test loss = 1.130640

Test accuracy = 0.624

Στην δοκιμή που πραγματοποιήθηκε για setTransformers με ένα SAB block τα αποτελέσματα είναι τα εξής:

Best epoch's val loss = 1.414416

Test loss = 1.465357

Test accuracy = 0.514000

4.3 Σχολιασμός αποτελεσμάτων DeepSets και SetTransformers για το Citeseer dataset

Τα αποτελέσματα των δύο αρχιτεκτονικών στο CiteSeer dataset παρουσιάζουν ιδιαίτερο ενδιαφέρον. Τα Deep Sets επιτυγχάνουν 60% test accuracy, υπερβαίνοντας κατά 7.1 μονάδες το MLP baseline (52.9%, [1]), επιβεβαιώνοντας ότι η αξιοποίηση της γειτονικής πληροφορίας μέσω sum-pooling προσφέρει πραγματικό όφελος ακόμα και χωρίς κάποιο επιλεκτικό μηχανισμό προσοχής. Τα Set Transformers με 2 SAB blocks επιτυγχάνουν 62.40%, υπερβαίνοντας ελαφρώς την επίδοση της DeepSets αρχιτεκτονικής και υποδεικνύοντας πως ο μηχανισμός προσοχής επιτυχημένα ερμηνεύει βαθύτερες συσχετίσεις μεταξύ των γειτόνων.

Αξίζει να σημειωθεί ότι κατά τη διαδικασία πειραματισμού, η δοκιμή με 1 SAB block (αντί για 2) ανέδειξε έντονη ευαισθησία στην αρχικοποίηση των βαρών μιας και με διαφορετικά seeds, η σχετική απόδοση 1 SAB έναντι 2 SABs αντιστρεφόταν πλήρως. Αυτό αποτελεί ένδειξη ότι με μόλις 120 εκπαιδευτικούς κόμβους, η αρχιτεκτονική διαφορά μεταξύ 1 και 2 SAB blocks δεν είναι ο κυρίαρχος παράγοντας αλλά η ευαισθησία στην αρχικοποίηση των βαρών κυριαρχεί, καθιστώντας αδύνατη την εξαγωγή ασφαλών συμπερασμάτων από τη σύγκριση αυτή.

Και οι δύο αρχιτεκτονικές υπολείπονται σημαντικά των GNN μεθόδων όπως το GCN (67.5%) και το GAT (70.6%), [1], οι οποίες εκμεταλλεύονται επαναληπτικά τη δομή του γράφου μέσω message passing. Η διαφορά αυτή είναι αναμενόμενη αφού τόσο τα Deep Sets όσο και τα SetTransformers αντιμετωπίζουν τη γειτονιά κάθε κόμβου ως ένα ανεξάρτητο, μη δομημένο σύνολο, χωρίς να εκμεταλλεύονται την ευρύτερη τοπολογία/δομή του γράφου πέρα από τους άμεσους γείτονες. Τα αποτελέσματα δεν μπορούν να συγκριθούν άμεσα με την αρχική μελέτη των SetTransformers [2], καθώς εκεί δεν αξιολογήθηκαν datasets με transductive learning χαρακτήρα όπως το CiteSeer.

Μοντέλο	Synthetic	CiteSeer	Early Stop
Deep Sets	96.16%	60%	12 / 30
Set Transformer (2 SABs)	95.80%	62.40%	13 / 33
Set Transformer (1 SAB)	95.72%	51.40%	10 / 23
MLP baseline [1]	—	52.90%	—
GCN [1]	—	67.50%	—
GAT [1]	—	70.60%	—

Πίνακας 4.1: Συγκριτικά αποτελέσματα για το test accuracy στα Deep Sets και στα Set Transformers στο συνθετικό και στο CiteSeer dataset. Η στήλη Early Stop αναφέρεται στο epoch τερματισμού για το συνθετικό και το CiteSeer dataset αντίστοιχα. Τα αποτελέσματα MLP, GCN και GAT προέρχονται από τη βιβλιογραφία και αφορούν αποκλειστικά το CiteSeer dataset.

4.3.1 Σημείωση για reproducibility

Τα αποτελέσματα των Set Transformers αντιστοιχούν σε seed=45, ενώ τα Deep Sets σε seed=42.

4.3.2 Ανάλυση ευαισθησίας: Το αντίκτυπο του weight initialization

Η αδυναμία που εμφανίστηκε όσο αφορά την εξαγωγή ασφαλών συμπερασμάτων ανεξαρτήτως του seed που ορίζεται κατά το training στην περίπτωση του SetTransformersCiteSeer, οδηγεί στην ανάγκη για περαιτέρω πειραματισμό, σχετικά με την ευαισθησία του μοντέλου στην αρχικοποίηση των βαρών, στις περιπτώσεις του 1 SAB και των 2 SABs. Έτσι, δημιουργείται διαδικασία η οποία εκτελεί τη διαδικασία της εκπαίδευσης για διαφορετικά seeds με στόχο να καταγραφεί το μέσο και η διακύμανση της απόδοσης για το εν λόγω μοντέλο στις περιπτώσεις του ενός και των δύο SABs. Τα εξαγόμενα αποτελέσματα είναι τα εξής:

Model	Seed	Early Stop (epoch)	Test Accuracy
1 SAB	42	28	0.5280
	43	30	0.5330
	44	25	0.4640
	45	23	0.5140
	46	30	0.5940
	Mean	—	0.5266 ± 0.0416
2 SABs	42	28	0.4980
	43	31	0.5740
	44	27	0.5410
	45	33	0.6240
	46	30	0.5560
	Mean	—	0.5586 ± 0.0412

Πίνακας 4.2: Sensitivity analysis στο CiteSeer dataset: 1 SAB vs 2 SABs σε 5 τυχαία seeds.

Όπως αναδεικνύεται και από τα παραπάνω αποτελέσματα, οι αποδόσεις στις δύο περιπτώσεις επικαλύπτονται, με το μέσο να διαφέρει κατά 0.032 στις δύο περιπτώσεις, την ώρα που η τυπική απόκλιση είναι μεγαλύτερη (0.041). Χαρακτηριστικό παράδειγμα αποτελεί το seed 42, όπου η αρχιτεκτονική με 1 SAB (0.528) υπερτερεί αυτής με 2 SABs (0.498), επιβεβαιώνοντας την πλήρη αντιστροφή της κατάταξης που είχε παρατηρηθεί αρχικά. Αυτό οδηγεί στο συμπέρασμα ότι λόγω του περιορισμένου αριθμού δειγμάτων για την εκπαίδευση και του transductive learning πλαισίου του Citeseer dataset, δεν μπορεί να εξαχθεί ασφαλές συμπέρασμα για το ποια αρχιτεκτονική προτιμάται. Το συμπέρασμα αυτό έρχεται να επιβεβαιώσει την αρχική τοποθέτηση, ότι η αρχιτεκτονική του μοντέλου δεν είναι το πρώτιστο θέμα στην περίπτωση αυτή, αλλά το ζήτημα έγκειται στην αραιότητα του dataset και στην ιδιαίτερη φύση του. Επομένως, τα αποτελέσματα που παρουσιάστηκαν στην ενότητα 4.2 όπου το test accuracy ισούται με 0.624, αποτελούν την υψηλότερη παρατηρηθείσα απόδοση στα πειράματά μας για το dataset αυτό.

4.4 Ερευνητικά ερωτήματα

4.4.1 Expressivity analysis

Όπως έχει αναλυθεί και στα προηγούμενα κεφάλαια, η αρχιτεκτονική των DeepSets και των SetTransformers μπορούν να αξιοποιηθούν για την προσέγγιση κάθε permutative invariant συνάρτησης. Αυτό σημαίνει ότι σε κάθε μια από τις δύο περιπτώσεις, μπορεί να προσδιοριστεί το απαιτούμενο πλήθος παραμέτρων ώστε η εν λόγω αρχιτεκτονική να μοντελοποιεί το πρόβλημα. Από την άλλη όμως πλευρά, το γεγονός αυτό, δεν εγγυάται ότι η διαδικασία εκπαίδευσης και εκμάθησης αυτών των παραγόντων, θα είναι το ίδιο εύκολη και στις δύο περιπτώσεις.

Πιο συγκεκριμένα, η αρχιτεκτονική DeepSets εμφανίζει μεγαλύτερη δυσκολία στην εκμάθηση "ανά-δύο" ομοιοτήτων μεταξύ των στοιχείων της, μιας και λόγω της φύσης της αρχιτεκτονικής κάθε στοιχείο γίνεται αντικείμενο επεξεργασίας ξεχωριστά. Αντίθετα, η αρχιτεκτονική των SetTransformers διαθέτει τον SAB μηχανισμό, ο οποίος κωδικοποιεί ανά δύο τις ομοιότητες των στοιχείων. Επομένως, οι διαφορές στην αρχιτεκτονική των δύο περι-

πτώσεων, δεν επηρεάζει το τι μπορεί να αναπαρασταθεί αλλά επηρεάζει την αποτελεσματικότητα και την αξιοπιστία με την οποία κάθε περίπτωση μπορεί να εκπαιδευτεί σε διαφορετικές καταστάσεις. Η αρχιτεκτονική διαφορά αυτή ορίζεται στη βιβλιογραφία ως *inductive bias* και σχετίζεται με τις "παραδοχές" που είναι ενσωματωμένες στην αρχιτεκτονική σχετικά με το ποιες συναρτήσεις είναι εύκολο να μαθευτούν.

Για να μπορέσει να αξιολογηθεί η ικανότητα ή μη, των DeepSets μοντέλων να προσομοιάσουν τη συμπεριφορά πιο "εκφραστικών" μοντέλων όπως τα setTransformers, θα χρησιμοποιηθεί το παράδειγμα εύρεσης του μέγιστου σε ένα set. [3]. Σύμφωνα με τη βιβλιογραφία, τα DeepSets μπορούν να προσεγγίσουν το πρόβλημα ορίζοντας:

$$\phi(x) = [e^{\alpha x}, x e^{\alpha x}], \quad \rho([u, v]) = \frac{v}{u}$$

Και όταν $\alpha \rightarrow \infty$:

$$\frac{\sum_i x_i e^{\alpha x_i}}{\sum_i e^{\alpha x_i}} \longrightarrow \max_i x_i$$

Οι παραπάνω τύποι αποδεικνύουν ότι υπάρχει μια κατάλληλα ορισμένη ϕ , η οποία μπορεί να προσεγγίσει το συγκεκριμένο πρόβλημα. Όμως καθώς το α τείνει στο άπειρο προκύπτουν προβλήματα, τα οποία δυσκολεύουν τη διαδικασία της εκπαίδευσης του μοντέλου. Συγκεκριμένα, η συνάρτηση $e^{\alpha x}$ για μεγάλο α και μεγάλο X μπορεί να λάβει πολύ μεγάλες τιμές οι οποίες δεν μπορούν να απαρασταθούν σε 32bits floats από το pytorch (το pytorch θα γυρίσει inf). Επίσης, ένα σημαντικό πρόβλημα που προκύπτει είναι το πρόβλημα των vanishing gradients. Συγκεκριμένα ο τύπος της συνάρτησης ϕ μπορεί να γραφτεί και ως:

$$\frac{\sum_i x_i e^{\alpha x_i}}{\sum_i e^{\alpha x_i}} = \frac{\sum_i x_i e^{\alpha(x_i - x^*)}}{\sum_i e^{\alpha(x_i - x^*)}}$$

Η ισοδύναμη εξίσωση φανερώνει το πρόβλημα των vanishing gradients για τα στοιχεία που δεν αποτελούν τα μέγιστα του set. Συγκεκριμένα αυτά τα στοιχεία, δεδομένου ότι το α είναι πολύ μεγάλο θα παράγουν μηδενικά gradients, μην προσφέροντας πληροφορία κατά τη διάρκεια εκπαίδευσης του μοντέλου, με αποτέλεσμα, όταν αυτά τα στοιχεία αποτελούν το μέγιστο σε νέα δεδομένα, το μοντέλο να αδυνατεί να τα αναγνωρίσει σωστά.

Αντίθετα, οι SetTransformers επιλύουν το πρόβλημα μέσω του μηχανισμού softmax attention, ο οποίος είναι δομικά ισοδύναμος με τον πα-

ραπάνω τύπο αλλά υλοποιείται μέσω εκπαιδευσιμων πινάκων προβολής W_Q και W_K αντί ενός μοναδικού βαθμωτού α . Αυτό επιτρέπει στο μοντέλο να μάθει να εστιάζει στο μέγιστο στοιχείο σταδιακά μέσω ομαλής διαδικασίας gradient descent, χωρίς αριθμητική αστάθεια.

Για να επαληθευτεί πως το πρόβλημα αυτό "ταιριάζει περισσότερο στα δομικά χαρακτηριστικά των setTransformers, δημιουργήθηκε ένα μικρό πείραμα κατά το οποίο τα δύο μοντέλα προσπαθούν να βρουν το μέγιστο στοιχείο σε τυχαία ορισμένες ακολουθίες. Τα μοντέλα εκπαιδεύονται σε 50 epochs και τα αποτελέσματα που λαμβάνονται είναι αρκετά επεξηγηματικά. Συγκεκριμένα:

Model	Test MAE
Deep Sets	15.4238
Set Transformer	0.6985

Πίνακας 4.3: Σύγκριση test MAE ανάμεσα σε Deep Sets και Set Transformer.

Αξίζει να σημειωθεί ότι στα κύρια πειράματα της παρούσας εργασίας, η διαφορά απόδοσης μεταξύ DeepSets και SetTransformers στο CiteSeer dataset ήταν μικρή. Αυτό δεν αντιφάσκει με τα παραπάνω ευρήματα. Το CiteSeer δεν απαιτεί ισχυρή μοντελοποίηση ανά-δύο ομοιοτήτων για την κατηγοριοποίηση των κόμβων, καθώς κάθε κόμβος χαρακτηρίζεται από ένα πλούσιο διάνυσμα χαρακτηριστικών 3703 διαστάσεων. Το κυρίαρχο εμπόδιο στην περίπτωση αυτή δεν είναι η εκφραστικότητα της αρχιτεκτονικής αλλά η αραιότητα των δεδομένων εκπαίδευσης μιας και διατίθενται μόλις 120 labeled κόμβοι. Το χάσμα "εκφραστικότητας" μεταξύ των δύο αρχιτεκτονικών γίνεται ορατό μόνο όταν το task απαιτεί ρητή/αυστηρή μοντελοποίηση των σχέσεων μεταξύ στοιχείων, όπως στο πρόβλημα εύρεσης μεγίστου.

4.4.2 Invariance vs. Equivariance

Η έννοια του permutation invariance έχει αναλυθεί ήδη σε προηγούμενα κεφάλαια της παρούσας εργασίας. Συνοπτικά, μια συνάρτηση θεωρείται permutative invariant, όταν η έξοδος που παράγει είναι ανεξάρτητη της σειράς των εισόδων που δέχεται. Αντίθετα, κατά το permutation equivariance, μια συνάρτηση παράγει έξοδο που εξαρτάται από τη σειρά

των στοιχείων εισόδου της. Στην περίπτωση αυτή, αλλαγές στην σειρά των εισόδων οδηγούν σε αντίστοιχες αλλαγές στην έξοδο που παράγεται. Για παράδειγμα, το άθροισμα είναι παράδειγμα *permutative invariant* συνάρτησης ενώ ο πολλαπλασιασμός είναι *permutative equivariant*. Έστω το set 7,3,4 και f η συνάρτηση άθροισης των στοιχείων. Τότε $f(7,3,4) = f(3,7,4) = f(4,3,7) = 14$. Αντίθετα αν στόχος είναι ο πολλαπλασιασμός κάθε στοιχείου με το 2, θα προκύπτει $f(7,3,4) = [14,6,8]$, $f(3,7,4) = [6,14,8]$ και $f(4,3,7) = [8,6,14]$. Παρατηρείται δηλαδή, ότι η σειρά της εξόδου αλλάζει συμμετρικά με το πώς αλλάζει η σειρά των στοιχείων εισόδου.

Οι περιπτώσεις στις οποίες πρέπει να χρησιμοποιηθεί η ιδιότητα του *invariance*, είναι όταν ζητείται η παραγωγή μιας εξόδου από ένα ολόκληρο set όπως στο άθροισμα, στην εύρεση μεγίστου και συγκεκριμένα στην παρούσα εργασία στο συνθετικό και Citeseer dataset (δοσμένου ενός κόμβου και των γειτόνων του, ζητούμενο είναι η πρόβλεψη ενός label).

Όταν όμως ζητούμενο είναι η παραγωγή μιας πρόβλεψης για κάθε στοιχείο του set ή όταν η πρόβλεψη βασίζεται σε ολόκληρες δομές γράφων, τότε χρησιμοποιείται η έννοια του *equivariance*.

Στην παρούσα εργασία το πρόβλημα του labeling του Citeseer dataset διατυπώνεται ως *invariant* πρόβλημα, μιας και για ένα σύνολο κόμβων στο set, καλούμαστε να προβλέψουμε την ετικέτα ενός κόμβου. Το πρόβλημα αυτό όμως αν διατυπώνονταν ως "Βάση της συνολικής δομής του γράφου προσδιορίστε τις ετικέτες όλων των κόμβων" τότε θα το προσεγγίζαμε με *equivariant* χαρακτήρα. Βάση των αποτελεσμάτων μας και του [1] παρατηρούμε διαφορά της τάξεως των 10 μονάδων ανάμεσα στις *invariant* αρχιτεκτονικές και αυτές που εκμεταλλεύονται την δομή ολόκληρου του γράφου (GATs).

Η διαφορά αυτή οφείλεται στο γεγονός ότι οι *equivariant* αρχιτεκτονικές όπως τα GCN και GAT διατηρούν ξεχωριστές αναπαραστάσεις για κάθε κόμβο καθ' όλη τη διάρκεια της επεξεργασίας, επιτρέποντας τη διάδοση πληροφορίας σε βάθος πολλαπλών επιπέδων μέσω επαναληπτικού *message passing*. Αντίθετα, τα *invariant* μοντέλα της παρούσας εργασίας μετά το pooling βήμα, χάνουν την πληροφορία κάθε μεμονωμένου κόμβου και η ευρύτερη τοπολογία του γράφου δεν αξιοποιείται. Το GAT διατηρεί την *equivariant* δομή του GNN και εισάγει παράλληλα τον μηχανισμό προ-

σοχής των SetTransformers για τη στάθμιση των γειτόνων, εξηγώντας έτσι την υψηλότερη απόδοσή του έναντι του GCN.

Βιβλιογραφία

- [1] Michail Chatzianastasis, Giannis Nikolentzos, and Michalis Vazirgiannis. Supervised attention using homophily in graph neural networks, 2023.
- [2] Juho Lee, Yoonho Lee, Jungtaek Kim, Adam R. Kosiorek, Seungjin Choi, and Yee Whye Teh. Set transformer: A framework for attention-based permutation-invariant neural networks, 2019.
- [3] Manzil Zaheer, Satwik Kottur, Siamak Ravanbakhsh, Barnabas Poczos, Ruslan Salakhutdinov, and Alexander Smola. Deep sets, 2018.